

Kernel PCA

훈련 집합 $\mathbf{x}^1, \dots, \mathbf{x}^n \in \mathbb{R}^d$ 와 변환 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 에 대하여

$$\phi(X) = \begin{bmatrix} \phi(\mathbf{x}^1)^T \\ \vdots \\ \phi(\mathbf{x}^n)^T \end{bmatrix}$$

의 주성분 분해에 대하여 알아보자. 식을 단순화하기 위하여, 우선 $\phi(X)$ 대신 일반적인 행렬을 사용하여 계산한다. 앞으로 등장할 행렬 A 는 $\phi(X)$ 라 생각하면 된다.

커널 (또는 커널 함수) k 는

$$k(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x}) \cdot \phi(\mathbf{y})$$

로 정의된다.

1. 공분산 행렬과 커널 행렬

$A = (a_{ij})$ 를 $n \times m$ 행렬이라 하고 A 의 i 행을 전치한 행렬(벡터)를 A^i 라 하자.

$$A^i = \begin{bmatrix} a_{i1} \\ \vdots \\ a_{im} \end{bmatrix}, \quad A = \begin{bmatrix} A^{1T} \\ \vdots \\ A^{nT} \end{bmatrix}$$

또, 두 행렬 C 와 K 를 각각

$$C = A^T A, \quad K = A A^T$$

라 하자. $\frac{1}{n}C$ 와 K 는 각각 공분산 행렬(covariance matrix)과 커널 행렬(kernel matrix)이라 한다. 행렬 C 는 다음과 같이 표현할 수도 있다.

$$C = \sum_{i=1}^n A^i A^{iT} \quad (1)$$

C 의 고유 값을 $\lambda_1, \dots, \lambda_m$, 대응되는 고유 벡터를 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^m$ 이라 하자. C 가 대칭 행렬이므로 고유 벡터들은 정규 직교 기저를 이룬다.

따라서 A^i 는 고유 벡터들의 일차 결합으로 표현된다. $A^i = \sum_{k=1}^m \alpha_k^i \mathbf{v}_k$ 라 하고 α_k^i 를 구하면

$$\alpha_k^i = A^i \cdot \mathbf{v}_k = A^{iT} \mathbf{v}_k \quad (2)$$

를 얻는다. 여기서

$$\boldsymbol{\alpha}_k = \begin{bmatrix} \alpha_k^1 \\ \vdots \\ \alpha_k^n \end{bmatrix} = \begin{bmatrix} A^{1T} \mathbf{v}_k \\ \vdots \\ A^{nT} \mathbf{v}_k \end{bmatrix} \in \mathbb{R}^n$$

라 하면

$$\boldsymbol{\alpha}_k = A \mathbf{v}_k \quad (3)$$

임을 알 수 있다.

고유 방정식 $C \mathbf{v}_k = \lambda_k \mathbf{v}_k$ 에 식 (1) 을 대입하고 식 (2) 를 적용하면

$$\lambda_k \mathbf{v}_k = \sum_{i=1}^n A^i A^{iT} \mathbf{v}_k = \sum_{i=1}^n \alpha_k^i A^i$$

와 같다. 위 식의 오른쪽 항은 $A^T \boldsymbol{\alpha}_k$ 와 같으므로

$$\lambda_k \mathbf{v}_k = A^T \boldsymbol{\alpha}_k \quad (4)$$

를 얻는다.

◇ 식 (2) 대신 식 (3)을 α_k 의 정의로 사용해도 동일한 결과를 얻는다.

◇ 두 행렬 C 와 K 가 서로 쌍대(dual) 형식이듯 두 식 (3)과 (4)도 서로 쌍대 형식이다. A 와 A^T 의 역할을 바꾸면 C 와 K 의 역할이 바뀌고 식 (3)과 (4)의 역할이 바뀐다.

◇ α_k 의 정의를 $c_k \alpha_k = A v_k$, $c_k \in \mathbb{R}$ 로 바꾸면 식 (4)는 $\lambda_k / c_k v_k = A^T \alpha_k$ 로 바뀐다. 고유값 λ_k 를 식 (3)과 (4)가 나누어 가질 수 있다.

커널 행렬 K 에 α_k 를 곱하여 식 (3)을 적용하면

$$K \alpha_k = A A^T A v_k = A C v_k = \lambda_k A v_k = \lambda_k \alpha_k$$

를 얻는다. 따라서 λ_k 와 α_k 는 각각 K 의 고유값과 고유 벡터이다.

여기서 생각해 볼 점은 기저 v_1, \dots, v_m 에 대한 A^i 의 성분이 $\alpha_1^i, \dots, \alpha_m^i$ 이라는 것, 다시 말하면, 커널 행렬의 고유 벡터의 성분이 $\phi(x^i)$ 의 성분이라는 것이다.

우리의 목표는 PCA에 있으므로 $\lambda_1 \geq \dots \geq \lambda_m$ 이라 가정하자. A^i 곧, $\phi(x^i)$ 의 k 차원 주 성분은 $(\alpha_1^i, \dots, \alpha_k^i)$ 임을 알 수 있다.

2. 예측(prediction)

임의의 벡터 $x \in \mathbb{R}^d$ 에 대하여 $\phi(x) \in \mathbb{R}^m$ 을 정규 직교 기저 v_1, \dots, v_m 의 일차 결합으로 표현

하여 주성분을 구해보자. $\phi(x) = \sum_{k=1}^m \gamma_k v_k$ 라 하면 $\gamma_k = \phi(x) \cdot v_k = \phi(x)^T v_k$ 이 성립한다. 식

(4)를 대입하면

$$\gamma_k = \phi(x)^T v_k = \frac{1}{\lambda_k} \phi(x)^T \phi(X)^T \alpha_k = \frac{1}{\lambda_k} (\phi(X) \phi(x)) \cdot \alpha_k$$

를 얻는다. $\phi(X) \phi(x)$ 는

$$\phi(X) \phi(x) = \begin{bmatrix} \phi(x_1) \cdot \phi(x) \\ \vdots \\ \phi(x_n) \cdot \phi(x) \end{bmatrix} = \begin{bmatrix} k(x_1, x) \\ \vdots \\ k(x_n, x) \end{bmatrix}$$

이다.

3. zero-centered 커널

행렬 A 의 j 열의 평균을 μ_j 라 하자. 곧, $\mu_j = \frac{1}{n} \sum_{i=1}^n a_{ij}$ 라 하자. 또, A 의 각 열에서 그 열의

평균을 뺀 행렬을 \tilde{A} 라 하자.

$$\tilde{A} = \begin{bmatrix} a_{11} - \mu_1 & \dots & a_{1m} - \mu_m \\ \vdots & \ddots & \vdots \\ a_{n1} - \mu_1 & \dots & a_{nm} - \mu_m \end{bmatrix}$$

커널 행렬 $\tilde{K} = \tilde{A} \tilde{A}^T$ 를 K 를 써서 표현해보자.

모든 성분이 $\frac{1}{n}$ 인 $n \times n$ 행렬을 J_n 이라 하면 $\tilde{A} = A - J_n A$ 을 확인할 수 있다. 따라서

$$\tilde{K} = K - K J_n - J_n K + J_n K J_n$$

을 얻는다.

4. 커널

자주 사용되는 커널은

Polynomial 커널

$$k(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + c)^p$$

RBF(radial basis function) 커널

$$k(\mathbf{x}, \mathbf{y}) = \exp(-\gamma \|\mathbf{x} - \mathbf{y}\|^2)$$

Hyperbolic tangent 커널

$$k(\mathbf{x}, \mathbf{y}) = \tanh(\mathbf{x} \cdot \mathbf{y} + c)$$

등이 있다. 이들의 경우 feature map ϕ 는 무엇인지 알아보자.

논의를 단순화하기 위하여

$$\mathbf{x} = (x_1, x_2), \quad \mathbf{y} = (y_1, y_2)$$

라 하자.

Polynomial 커널에서 $p = 2$, $c = 0$ 이라 하고

$$\phi(\mathbf{x}) \cdot \phi(\mathbf{y}) = (\mathbf{x} \cdot \mathbf{y})^2$$

을 만족하는 feature map ϕ 를 찾아보자.

$$\begin{aligned} (\mathbf{x} \cdot \mathbf{y})^2 &= (x_1 y_1 + x_2 y_2)^2 \\ &= x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 x_2 y_1 y_2 \\ &= (x_1^2, \sqrt{2} x_1 x_2, x_2^2) \cdot (y_1^2, \sqrt{2} y_1 y_2, y_2^2) \end{aligned}$$

이므로

$$\phi(\mathbf{x}) = (x_1^2, \sqrt{2} x_1 x_2, x_2^2)$$

이라 하면 된다. 일반적인 경우도 비슷하다.

RBF 커널에서 $\gamma = 1/2$ 이라 하고 ϕ 를 찾아보자.

$$\exp(-\frac{1}{2} \|\mathbf{x} - \mathbf{y}\|^2) = \exp(-\frac{1}{2} \|\mathbf{x}\|^2) \exp(-\frac{1}{2} \|\mathbf{y}\|^2) \exp(x_1 x_2 y_1 y_2)$$

$$\begin{aligned} \exp(x_1 x_2 y_1 y_2) &= 1 + x_1 x_2 y_1 y_2 + \frac{1}{2} x_1^2 x_2^2 y_1^2 y_2^2 + \dots \\ &= (1, x_1 x_2, x_1^2 x_2^2, \dots) \cdot (1, y_1 y_2, y_1^2 y_2^2, \dots) \end{aligned}$$

이므로

$$\phi(x_1, x_2) = e^{-\frac{1}{2}(x_1^2 + x_2^2)} (1, x_1 x_2, x_1^2 x_2^2, \dots)$$

임을 알 수 있다.