

## Kernel PCA

훈련 집합  $\mathbf{x}^1, \dots, \mathbf{x}^n \in \mathbb{R}^d$ 와 변환  $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 에 대하여

$$\phi(X) = \begin{bmatrix} \phi(\mathbf{x}^1)^T \\ \vdots \\ \phi(\mathbf{x}^n)^T \end{bmatrix}$$

의 주성분 분해에 대하여 알아보자. 식을 단순화하기 위하여  $\phi(X)$  대신 일반적인 행렬을 사용하여 계산한다. 앞으로 등장할 행렬  $A$ 는  $\phi(X)$ 라 생각하면 된다.

$A = (a_{ij})$ 를  $n \times m$  행렬이라 하고  $A$ 의  $i$  행을 전치한 벡터를  $A^i$ 라 하자.

$$A^i = \begin{bmatrix} a_{i1} \\ \vdots \\ a_{im} \end{bmatrix}, \quad A = \begin{bmatrix} A^{1T} \\ \vdots \\ A^{nT} \end{bmatrix}$$

또, 두 행렬  $C$ 와  $K$ 를 각각

$$C = A^T A, \quad K = A A^T$$

라 하자.

$C$ 의 고유 값을  $\lambda_1, \dots, \lambda_m$ , 대응되는 고유 벡터를  $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^m$ 이라 하자.  $C$ 가 대칭 행렬이므로 고유 벡터들은 정규 직교 기저를 이룬다. 또,  $C\mathbf{v}_k = \lambda_k \mathbf{v}_k$ ,  $C = \sum_{i=1}^n A^i A^{iT}$ 이므로

$$\lambda_k \mathbf{v}_k = \sum_{i=1}^n A^i A^{iT} \mathbf{v}_k$$

가 성립한다.

$\alpha_k^i = A^{iT} \mathbf{v}_k = A^i \cdot \mathbf{v}_k$ 라 하면

$$\lambda_k \mathbf{v}_k = \sum_{i=1}^n \alpha_k^i A^i$$

와 같이,  $\mathbf{v}_k$ 를  $A^i$ 의 일차 결합으로 나타낼 수 있다. 여기서

$$\boldsymbol{\alpha}_k = \begin{bmatrix} \alpha_k^1 \\ \vdots \\ \alpha_k^n \end{bmatrix} \in \mathbb{R}^n$$

이라 하면

$$\lambda_k \mathbf{v}_k = A^T \boldsymbol{\alpha}_k \tag{1}$$

가 성립한다.

◇ 참고로

$$C\mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad K A \mathbf{v}_i = \lambda_i A \mathbf{v}_i$$

가 성립한다.  $C$ 와  $K$ 의 역할을 바꾸어도 유사한 관계가 성립한다.

식  $A^T A \mathbf{v}_k = \lambda_k \mathbf{v}_k$ 의 양변에  $\lambda_k$ 을 곱하고 식 (1)을 대입하면

$$A^T A A^T \boldsymbol{\alpha}_k = \lambda_k A^T \boldsymbol{\alpha}_k$$

이고, 다시 양변에  $A$ 를 곱하여

$$K^2 \boldsymbol{\alpha}_k = \lambda_k K \boldsymbol{\alpha}_k \tag{2}$$

를 얻는다. 양변에서  $K$ 를 소거하면

$$K \boldsymbol{\alpha}_k = \lambda_k \boldsymbol{\alpha}_k \tag{3}$$

이다. 곧,  $\alpha_k$ 는  $K$ 의 고유 벡터이다.

◇  $\alpha_k$ 를

$$\alpha_k = c A v_k$$

로 정의하면,  $K\alpha_k = \lambda_k \alpha_k$ 가 성립한다. 이 식을  $\alpha_k$ 의 정의로 사용하는 것도 한 방법이다.

행렬  $A$ 의 행  $A^i$ 는  $\mathbb{R}^m$  위의 벡터이므로 정규 직교 기저  $v_1, \dots, v_m$ 의 일차 결합으로 표시된다.  $A^i = \sum_{j=1}^m \beta_j^i v_j$ 라 하면  $\beta_k^i = A^i \cdot v_k = A^{iT} v_k$ 임을 알 수 있다.

$$\beta_k = \begin{bmatrix} \beta_k^1 \\ \vdots \\ \beta_k^n \end{bmatrix}$$

라 하면  $\beta_k = A v_k$ 가 성립하고, 식 (1)을 대입하면

$$\beta_k = A v_k = \frac{1}{\lambda_k} A A^T \alpha_k = \frac{1}{\lambda_k} K \alpha_k = \alpha_k \quad (4)$$

를 얻는다.

우리의 목표는 PCA에 있으므로  $\lambda_1 \geq \dots \geq \lambda_m$ 이라 가정하자. 식 (4)에서  $\phi(X)$ , 곧  $A$ 의  $k$  차원 주성분은

$$[\alpha_1 \dots \alpha_k] = \begin{bmatrix} \alpha_1^1 \dots \alpha_k^1 \\ \vdots & \ddots & \vdots \\ \alpha_1^n \dots \alpha_k^n \end{bmatrix}$$

임을 알 수 있다. 곧, 커널 행렬  $K = \phi(X)\phi(X)^T$ 의 고유 벡터들이  $\phi(X)$ 의 주성분을 이룬다.

예측(prediction)에 대하여 알아보자. 임의의 벡터  $x \in \mathbb{R}^d$ 에 대하여  $\phi(x) \in \mathbb{R}^m$ 을 정규 직교 기저  $v_1, \dots, v_m$ 의 일차 결합으로 표현하여 주성분을 구해보자.  $\phi(x) = \sum_{j=1}^m \gamma_j v_j$ 라 하면

$\gamma_k = \phi(x) \cdot v_k = \phi(x)^T v_k$ 이다. 식 (1)을 대입하면

$$\gamma_k = \phi(x)^T v_k = \frac{1}{\lambda_k} \phi(x)^T \phi(X)^T \alpha_k = \frac{1}{\lambda_k} (\phi(X)\phi(x)) \cdot \alpha_k$$

를 얻는다.  $\phi(X)\phi(x)$ 는

$$\phi(X)\phi(x) = \begin{bmatrix} \phi(x_1) \cdot \phi(x) \\ \vdots \\ \phi(x_n) \cdot \phi(x) \end{bmatrix} = \begin{bmatrix} k(x_1, x) \\ \vdots \\ k(x_n, x) \end{bmatrix}$$

이다.