인공 지능과 데이터 사이언스

박 경수
전주대학교 게임콘텐츠학과

인공 지능

- 지능이란?
  - 자연 지능 / 인공 지능
- 인공 지능
  - 지능을 구현한 컴퓨터 시스템
  - 논리 기반 시스템 / 경험(자료) 기반 시스템
- 기계 학습
  - 기계가 경험을 통하여 스스로 배우는 것
  - 지도 학습 / 비지도 학습 / 강화 학습

목차

- 지도 학습
- 비지도 학습
- 강화 학습

지도 학습
supervised learning

- 회귀(regression)
  - 내일 비가 올 확률
  - 우리 아이의 키는?
  - 투자의 손익

- 분류(classification)
  - 사진 속 꽃의 종 판별
  - 글자 인식

자료

- 실험이나 관측으로 얻은 자료
- 입력과 출력

x	x_1	x_2	$\cdots$	x_n
y	y_1	y_2	$\cdots$	y_n

- 자료에는 예측할 수 없는 다양한 잡음(noise)이 포함된다
  - 환경 요인
  - 측정 오차

목표

- 자료

$$\{(x_1, y_1), \dots, (x_n, y_n)\}$$

  - 훈련 집합(training set)
- 가정:

$$y = f(x) + \alpha$$

  - α: 잡음
- 목표:

$f(x)$의 근사식 $\hat{f}(x)$ 찾기

통계적 방법

- $\hat{f}(x)$의 형태를 추정
  - 일차 함수, 다항 함수, …
- 최소 제곱법
  - 최소 제곱 오차

$$L = \sum_{i=1}^{n} \| y_i - \hat{f}(x_i) \|^2$$

  - L을 최소로 하는 $\hat{f}(x)$를 구한다

보기

x	0.08	0.13	⋯	0.99
y	0.16	0.17	⋯	0.66

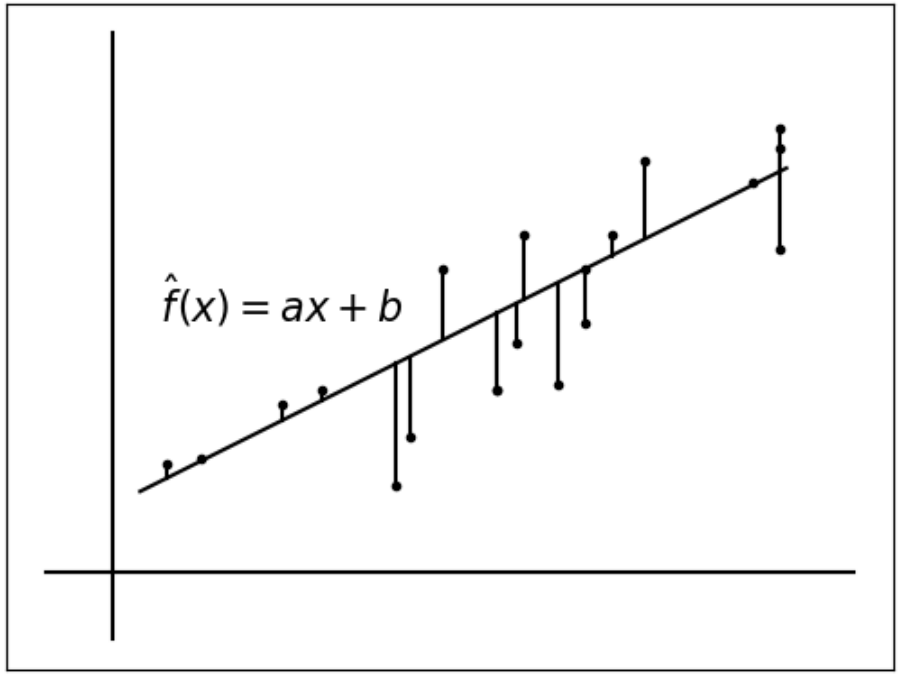

- $\hat{f}(x) = ax + b$라 추정
- L은

$$L = (0.16 - 0.08a - b)^2 + \cdots + (0.66 - 0.99a - b)^2$$

- L을 최소로 하는 a와 b를 구한다

순방향 신경망
Feedforward Neural Network

- 순환이 없는 신경망

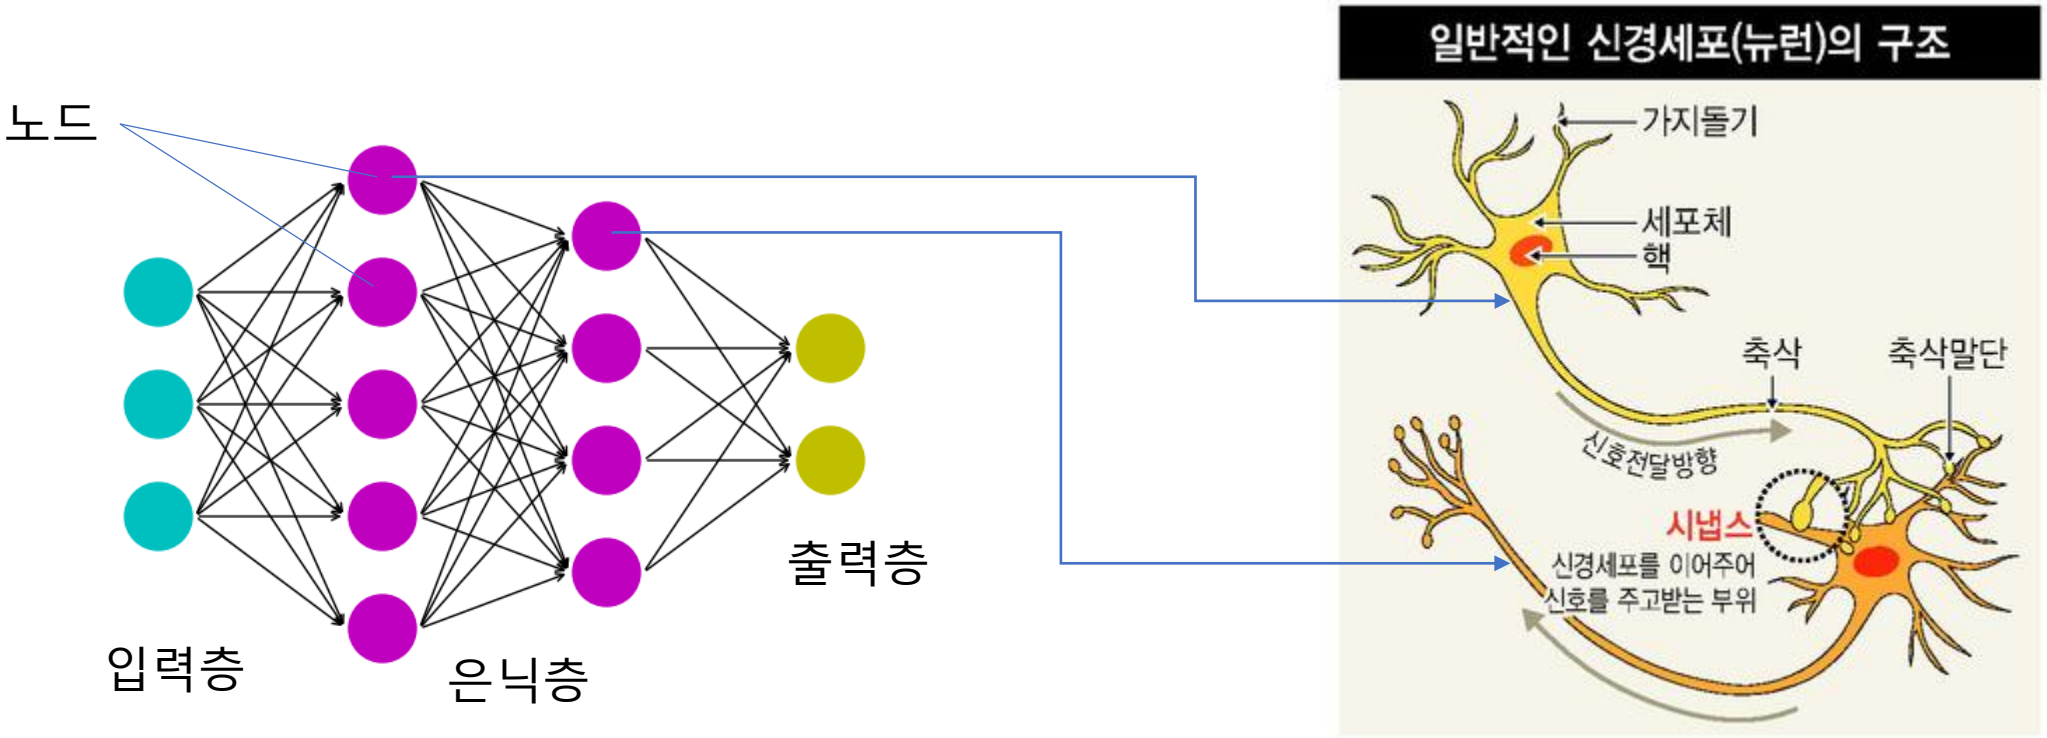

출처: 한겨레

자녀의 키

아빠의 키(x_1)	0.173	0.165	…	0.180
엄마의 키(x_2)	0.156	0.159	…	0.165
가계 소득(x_3)	0.300	0.450	…	0.280
아들의 키(y_1)	0.179	0.175	…	0.180
딸의 키(y_2)	0.160	0.165	…	0.158

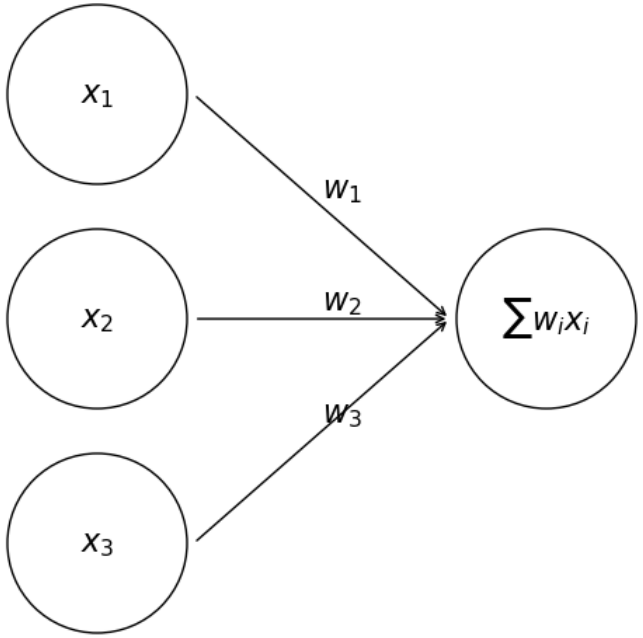

아들의 키

$w_1 = 0.6,\ w_2 = 0.3,\ w_3 = 0.1$이라 하면

$w_1 \cdot 0.173 + w_2 \cdot 0.156 + w_3 \cdot 0.300 = 0.1806$

오차: 0.0016

오차의 제곱의 합을 최소로 하는 $w_1,\ w_2,\ w_3$는?

단층 퍼셉트론

- 은닉층이 없는 신경망
  - w_i: 가중치
    - 각 요소의 비중
  - b: 바이어스(bias, 편향)
    - 상수항
  - ϕ: 활성 함수
    - 비선형, 증가, 미분가능
  - $\hat{y}_j$: 출력

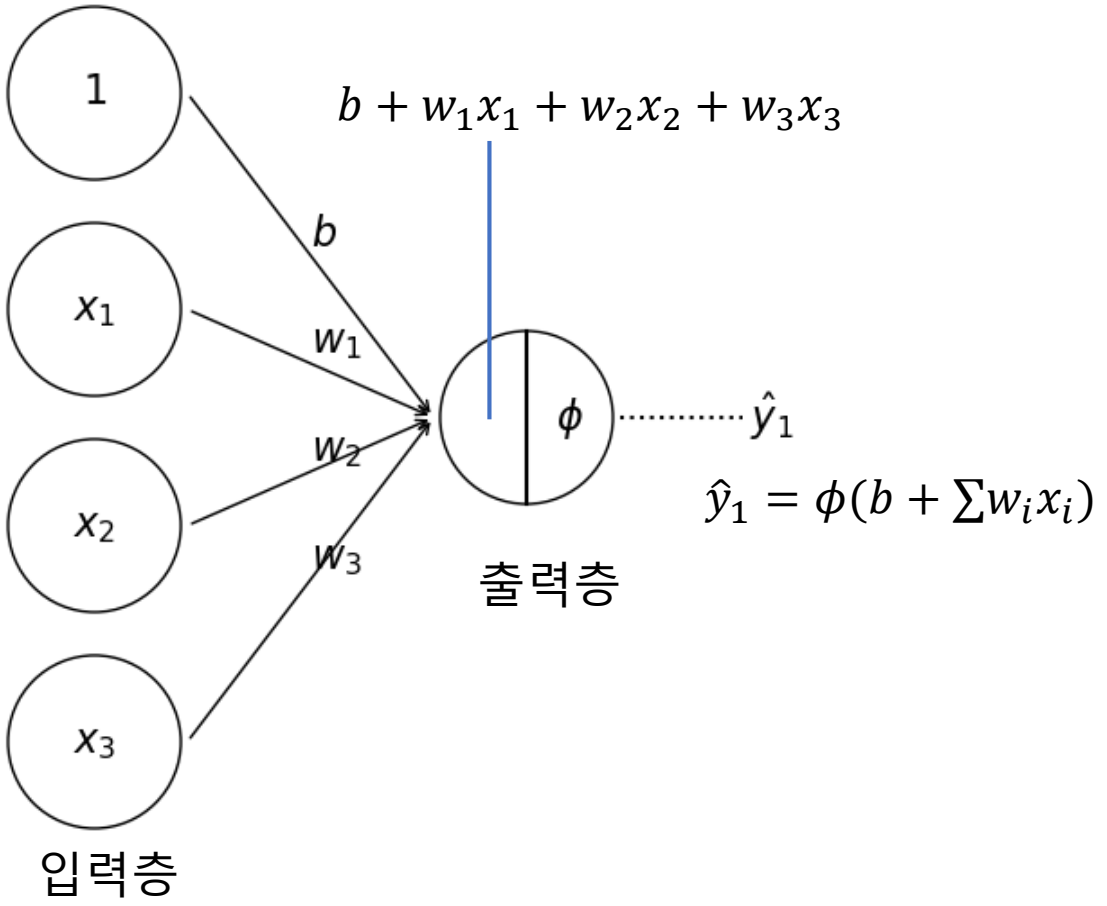

활성함수

- 시그모이드 함수
  - $\sigma(x) = \frac{1}{1+e^{-x}}$
- 쌍곡 탄젠트
  - $\tanh(x)$
- Rectifier
  - $\mathrm{ReLU}(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$

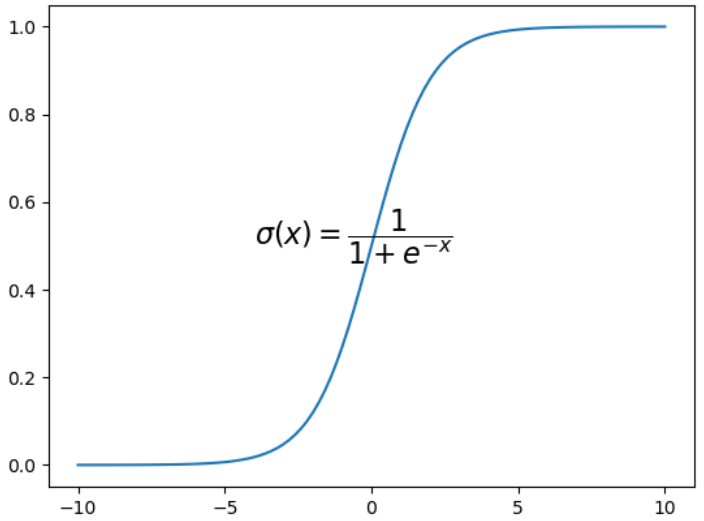

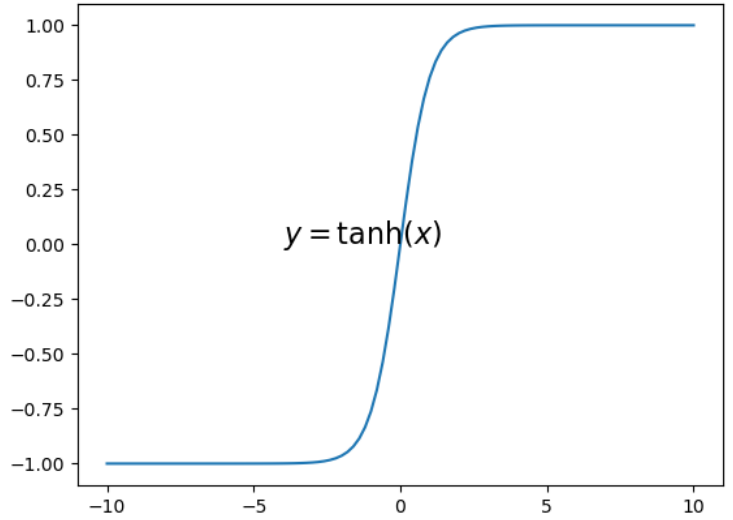

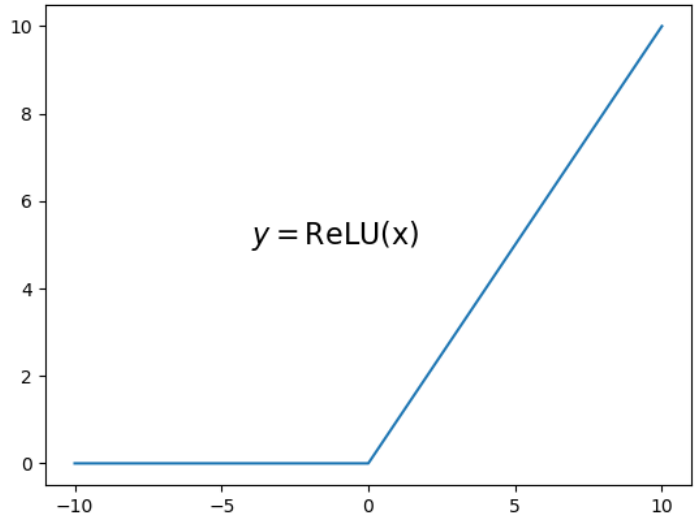

목표

- 아들의 키를 가장 잘 근사시키는 바이어스 b와 가중치 w_i는?

아빠의 키(x_1)	x_{11}	x_{12}	$\cdots$	x_{1n}
엄마의 키(x_2)	x_{21}	x_{22}	$\cdots$	x_{2n}
가계 소득(x_3)	x_{31}	x_{32}	$\cdots$	x_{3n}
아들의 키(y_1)	y_{11}	y_{12}	$\cdots$	y_{1n}

- $\hat{y}_{1i} = \phi(b + w_1 x_{1i} + w_2 x_{2i} + w_3 x_{3i})$
- 오차: $L = \frac{1}{2}\sum_{i=1}^{n}(y_{1i} - \hat{y}_{1i})^2$

그래디언트
Gradient

- 함수 $f: \mathbb{R}^n \to \mathbb{R}$
- 점 $x = (x_1, \ldots, x_n)$에서 f 의 그래디언트

$$\nabla_x f(x) = \nabla f(x) = \left(\frac{\partial f}{\partial x_1}(x), \ldots, \frac{\partial f}{\partial x_n}(x) \right)$$

  - 함수가 가장 빨리 증가하는 방향
- 보기: $f(x_1, x_2) = x_1^2 x_2$

$$\nabla f(x_1, x_2) = (2x_1 x_2, x_1^2)$$

- 그래디언트 벡터
  - $z = 1.5e^{-(x-1)^2-y^2} - e^{-(x+1)^2-y^2}$

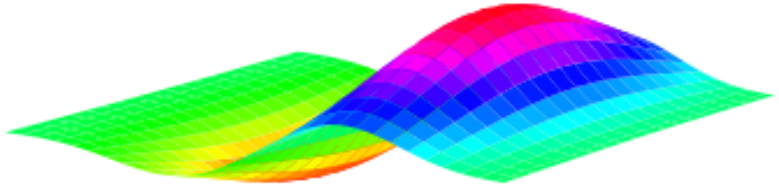

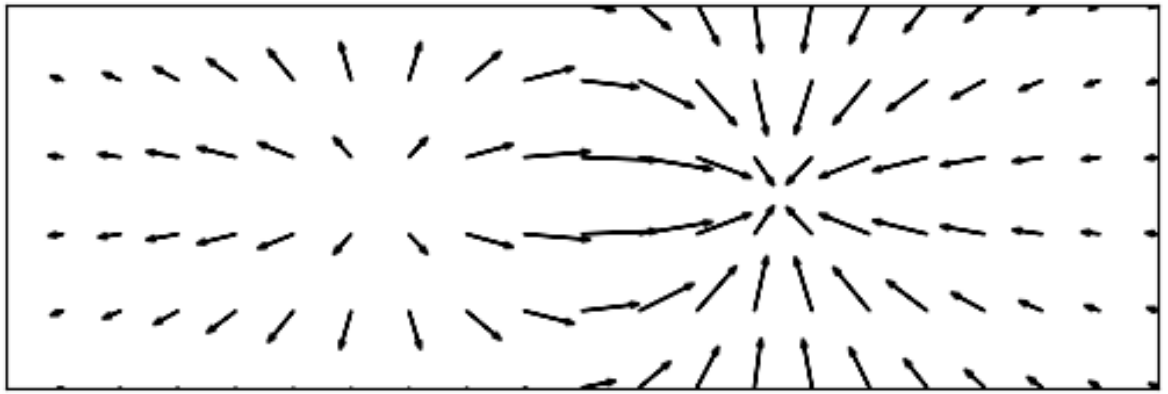

경사 하강법
Gradient Descent Method

- 함수 f의 극소점 찾기
- 알고리즘
  - p = 임의의 점, λ = 작은 실수
  - $f(p)$의 변화가 큰 동안 다음을 반복
    - $p \leftarrow p - \lambda \cdot \nabla f(p)$
- 학습률 λ
  - 실험을 반복하여 적당한 값을 찾는다
- p의 초기값에 따라 극소점이 다를 수도 있다

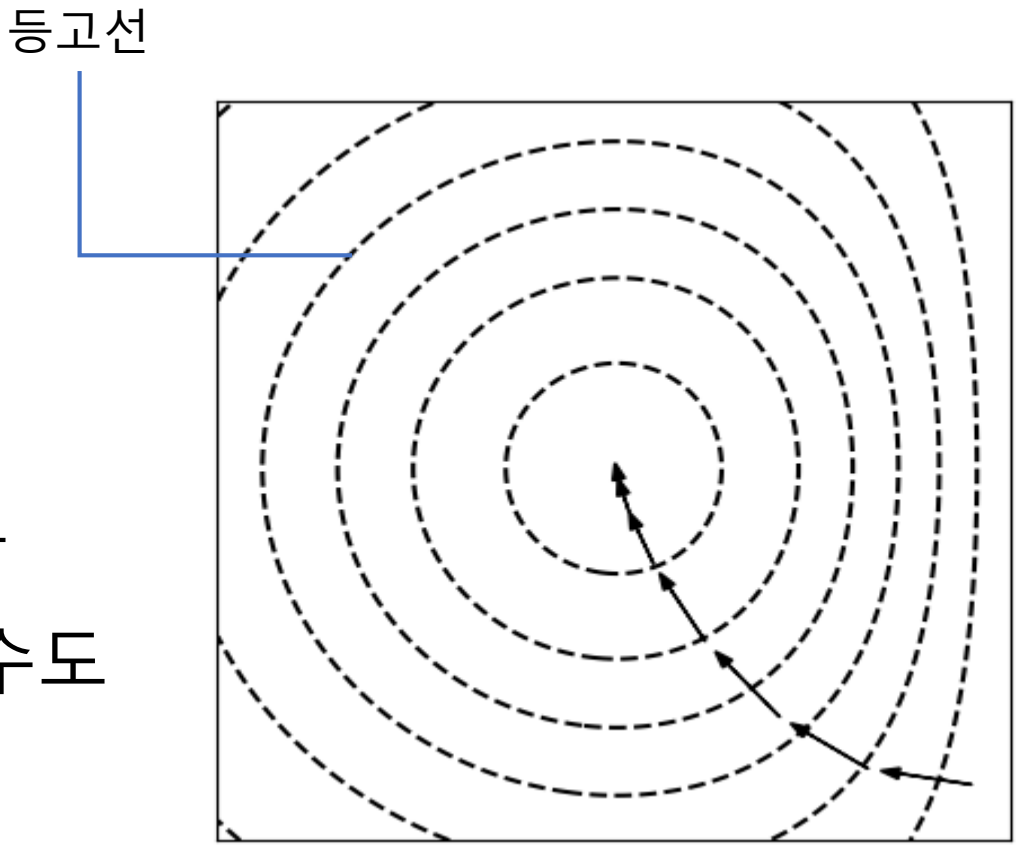

합성함수의 그래디언트

- 두 함수 $g: \mathbb{R}^m \to \mathbb{R}^n$, $f: \mathbb{R}^n \to \mathbb{R}$의 합성 함수

$$\mathbb{R}^m \xrightarrow{g} \mathbb{R}^n \xrightarrow{f} \mathbb{R}$$

$$y = g(x)$$

$$z = f(y) = f(g(x))$$

- g의 야코비 행렬

$$J_g(x) = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \cdots & \frac{\partial y_n}{\partial x_m} \end{bmatrix}$$

- 그래디언트(열벡터)

$$\nabla_x z = J_g(x)^T \nabla_y z$$

계산

아빠의 키(x_1)	x_{11}	x_{12}	$\cdots$	x_{1n}
엄마의 키(x_2)	x_{21}	x_{22}	$\cdots$	x_{2n}
가계 소득(x_3)	x_{31}	x_{32}	$\cdots$	x_{3n}
아들의 키(y_1)	y_{11}	y_{12}	$\cdots$	y_{1n}

- 근사값

$$\hat{y}_{1i} = \phi(b + \sum_{j=1}^{3} w_j x_{ji})$$

- 오차

$$L = \frac{1}{2}\sum_{i=1}^{n}(y_{1i} - \hat{y}_{1i})^2$$

- 미분

$$\frac{\partial L}{\partial w_1} = \sum_i (y_{1i} - \hat{y}_{1i}) \frac{\partial \hat{y}_{1i}}{\partial w_1}$$
$$= \sum_i (y_{1i} - \hat{y}_{1i}) \phi'\left(b + \sum_j w_j x_{ji}\right) x_{1i}$$

$$\nabla L = \begin{bmatrix} \frac{\partial L}{\partial b} & \frac{\partial L}{\partial w_1} & \frac{\partial L}{\partial w_3} & \frac{\partial L}{\partial w_3} \end{bmatrix}^T$$

$$= \begin{bmatrix} \sum_i (y_{1i} - \hat{y}_{1i}) \phi'\left(b + \sum_j w_j x_{ji}\right) \\ \sum_i (y_{1i} - \hat{y}_{1i}) \phi'\left(b + \sum w_j x_{ji}\right) x_{1i} \\ \sum_i (y_{1i} - \hat{y}_{1i}) \phi'\left(b + \sum w_j x_{ji}\right) x_{2i} \\ \sum_i (y_{1i} - \hat{y}_{1i}) \phi'\left(b + \sum w_j x_{ji}\right) x_{3i} \end{bmatrix}$$

- 행렬 표현
  - 훈련 집합

    $\{(x_1, y_1), \dots, (x_n, y_n)\}$
  - 변수

    $W = [b \quad w_1 \quad w_2 \quad w_3]$

    $X = \begin{bmatrix} 1 & \cdots & 1 \\ x_{11} & \cdots & x_{1n} \\ x_{21} & \cdots & x_{2n} \\ x_{31} & \cdots & x_{3n} \end{bmatrix}$

    $Z = F(X, W) = WX$

    $\hat{Y}_1 = \phi(Z)$
- L의 그래디언트

  $\nabla_W L = J_\phi(Z)^T \left(\hat{Y}_1 - Y_1\right) X^T$

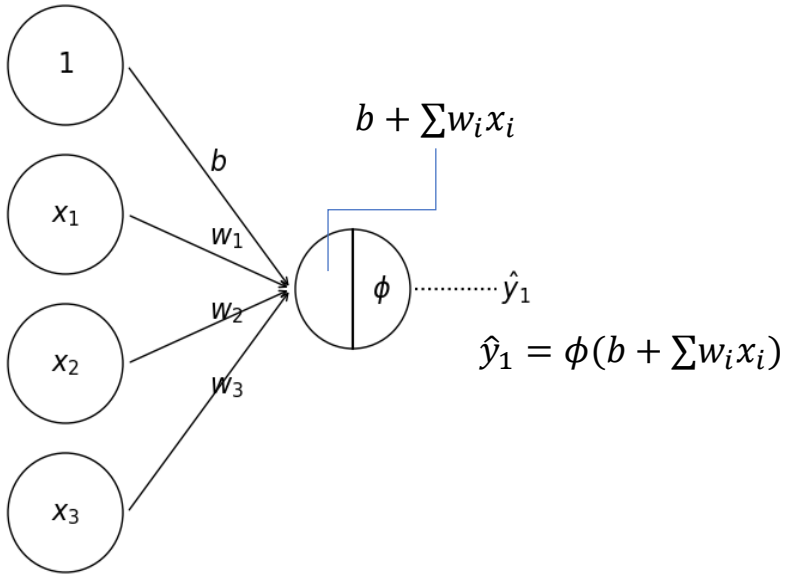

$$W \searrow$$

$$X \rightarrow Z \rightarrow \hat{Y}_1$$

다층 퍼셉트론

- 은닉층이 있는 순방향 신경망

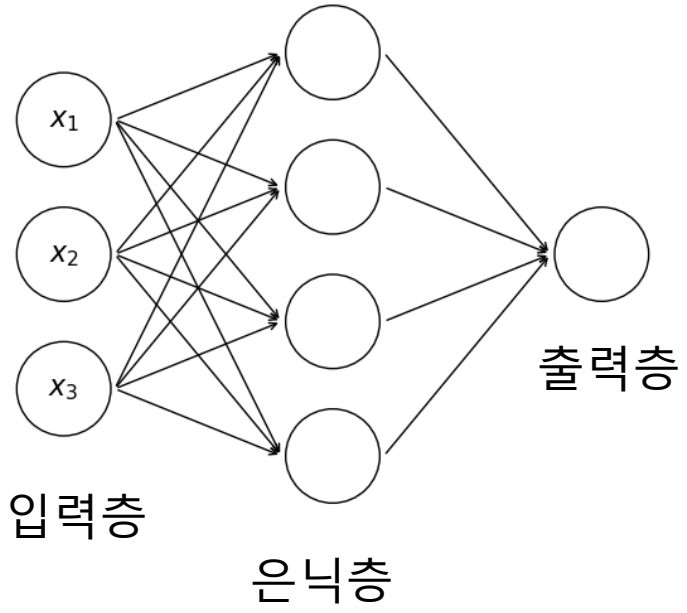

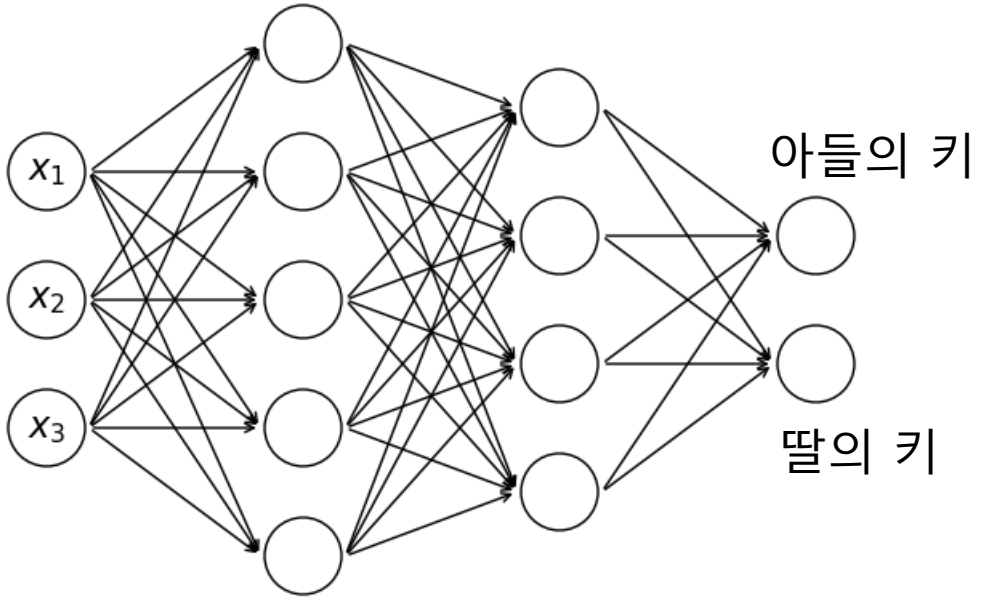

배타적 논리합(XOR)

$p \oplus q = (\sim p \wedge q) \vee (p \wedge \sim q)$

p	q	$p \oplus q$
F	F	F
F	T	T
T	F	T
T	T	F

x_1	0	0	1	1
x_2	0	1	0	1
y	0	1	1	0

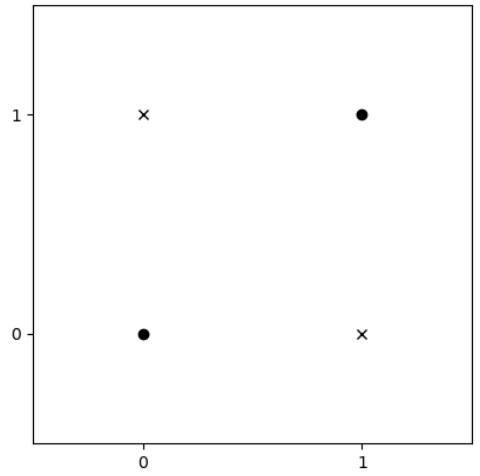

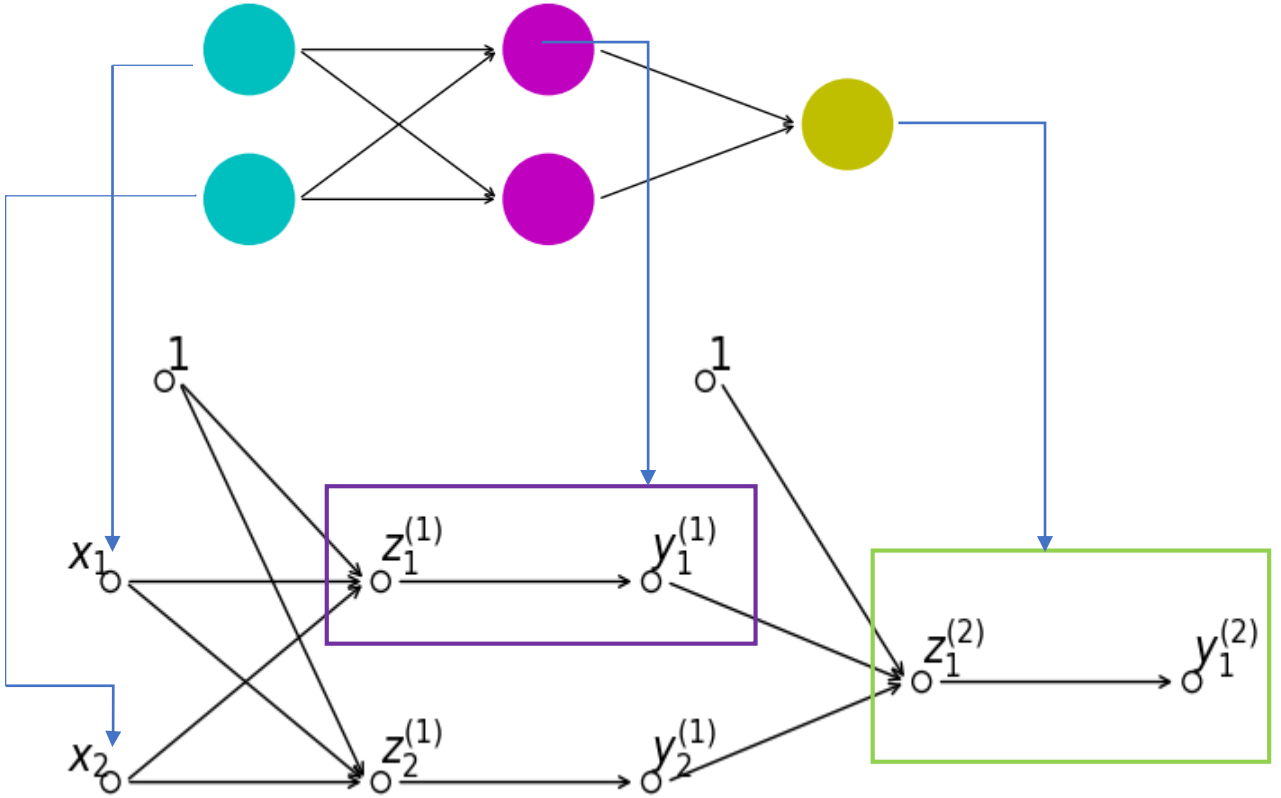

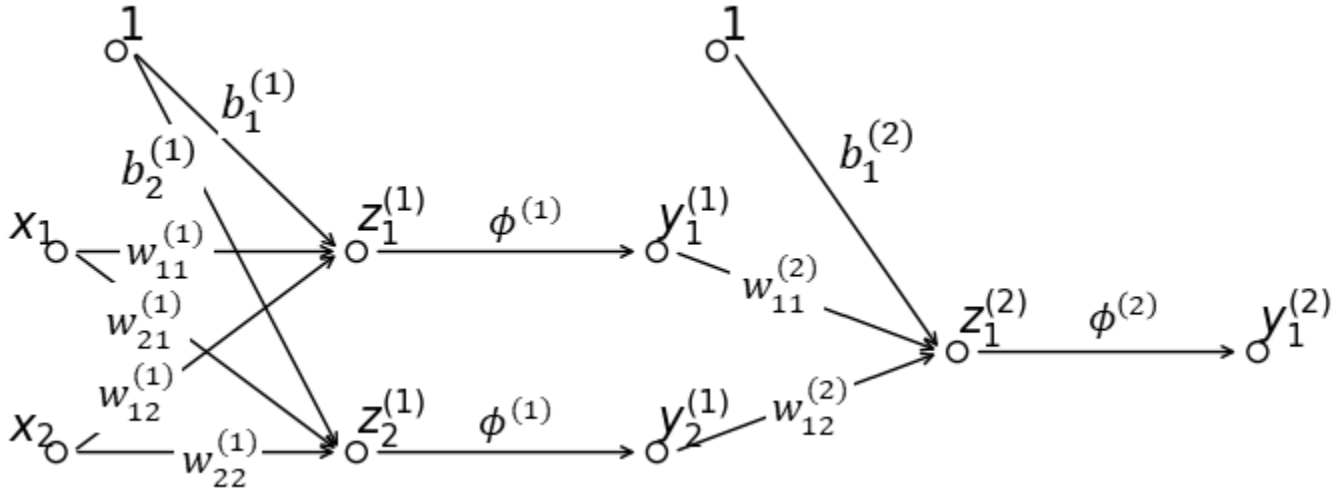

$$W^{(1)} \qquad\qquad W^{(2)}$$

$$\searrow \qquad\qquad \searrow$$

$$X \rightarrow Z^{(1)} \rightarrow Y_1^{(1)} \rightarrow Z^{(2)} \rightarrow Y^{(2)}$$

벡터 표현

$$z_1^{(1)} = b_1^{(1)} + w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2$$

$$y_1^{(1)} = \phi^{(1)}\left(z_1^{(1)}\right)$$

$$\vdots$$

행렬 표현

$$Z^{(1)} = W^{(1)} X$$

$$Y^{(1)} = \phi^{(1)}\left(Z^{(1)}\right)$$

$$\vdots$$

코드

```
import numpy as np
from keras import Sequential, losses
from keras.layers import Dense
import matplotlib.pyplot as plt

x = np.array([[0, 0], [0, 1], [1, 0], [1, 1]], 'float32')
t = np.array([[0, 1, 1, 0]], 'float32').T

model = Sequential()
model.add(Dense(2, input_dim=2, activation='sigmoid'))
model.add(Dense(1, activation='sigmoid'))
model.compile(loss=losses.mse, optimizer='adam')
result = model.fit(x, t, epochs=10000, verbose=2)
```

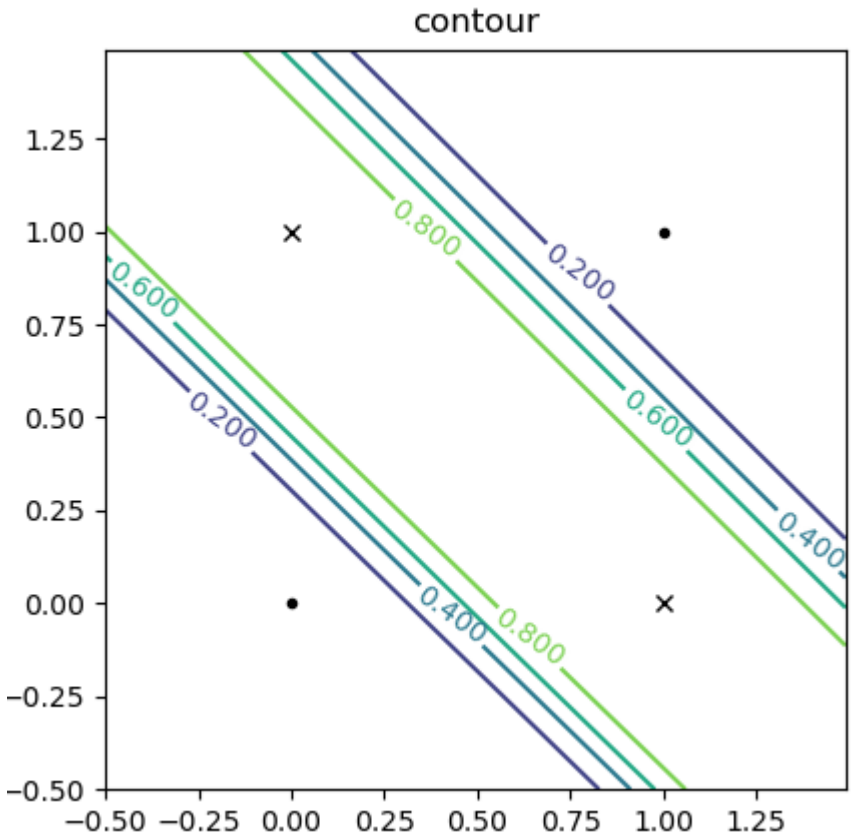

심층 학습
Deep Learning

- 심층 신경망을 사용하는 기계 학습
  - 심층 신경망 = 은닉층이 많은 신경망

합성곱
Convolution

1	4	3	3
2	0	8	9
5	6	8	5
8	7	7	3

그림

$*$

합성곱

0	1	0
1	2	1
0	1	0

필터

$=$

20	36
32	42

$2 \cdot 0 + 0 \cdot 1 + 8 \cdot 0$
$+5 \cdot 1 + 6 \cdot 2 + 8 \cdot 1$
$+8 \cdot 0 + 7 \cdot 1 + 7 \cdot 0$

0	0	0
1	1	1
0	0	0

가로선

0	1	0
0	1	0
0	1	0

세로선

1	0	0
0	1	0
0	0	1

대각선

0	0	1
0	1	0
1	0	0

대각선

*

0.2	0.2	0.2	0.2	0.2
0	0	0	0	0
0	0	0	0	0
0	0	0	0	0
0	0	0	0	0

=

0.2	0	0	0	0
0.2	0	0	0	0
0.2	0	0	0	0
0.2	0	0	0	0
0.2	0	0	0	0

=

합성곱 신경망
CNN – Convolutional Neural Network

- 합성곱을 포함하는 신경망

숫자 인식

- Mnist
  - 28 × 28 손글씨 6만개

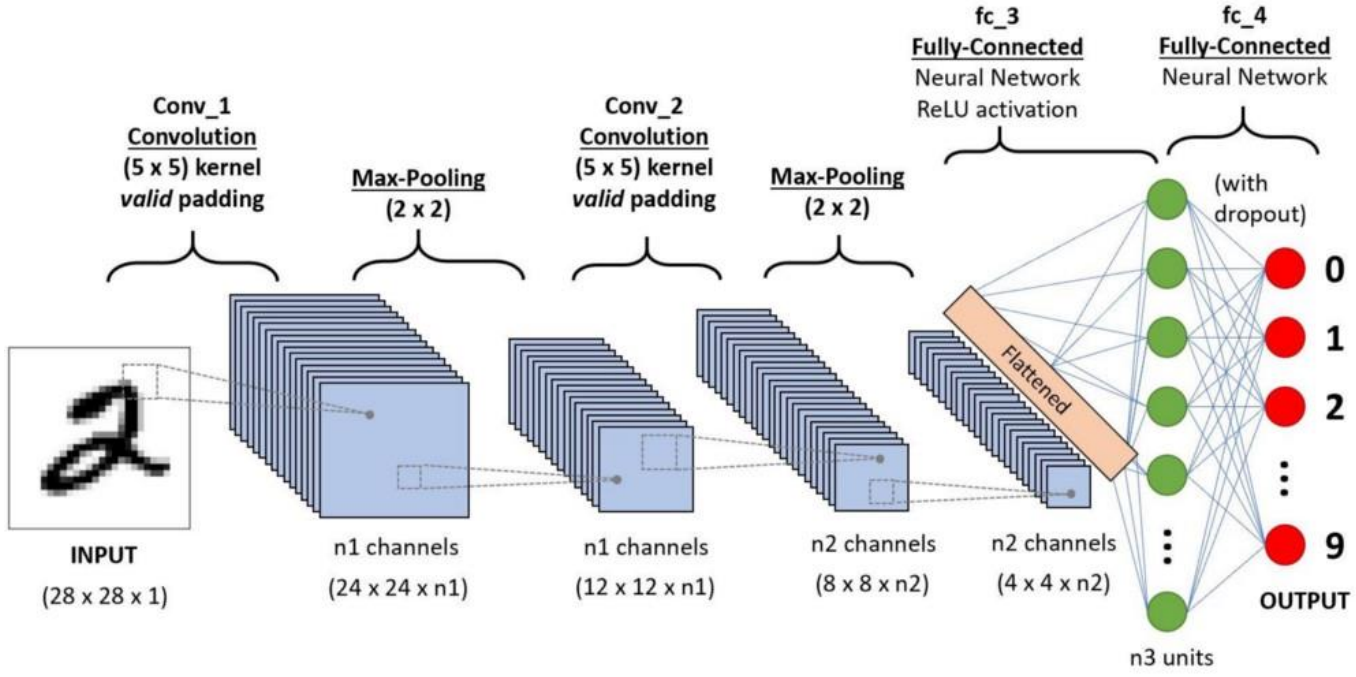

이미지 인식

- ResNet – 2015
  - 사람보다 좋은 인식률 95%
  - 34층
  - 노드 개수 ≈ 6천만

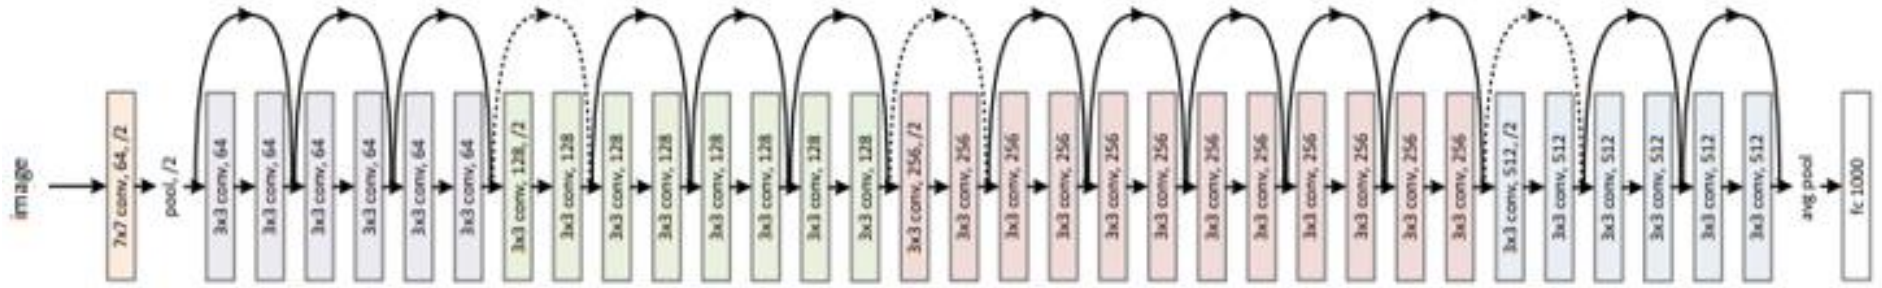

RNN – Recurrent Neural Network

- 작곡, 소설

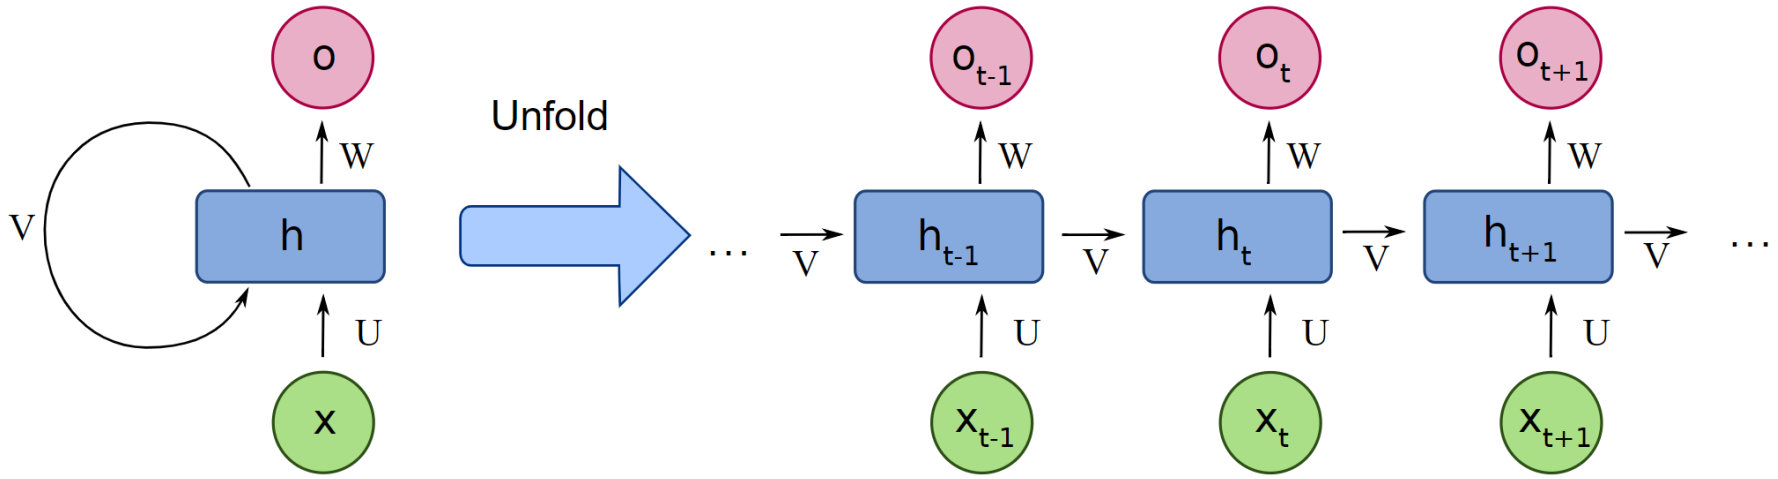

인공 신경망의 장단점

- 정확도가 높다
- 단점
  - 너무 복잡하여 인간이 이해하기 어렵다
    - ResNet은 변수가 6천만개인 함수의 극솟값을 계산한다
  - 치명적인 오류가 있어도 사전에 발견할 수 없다
    - 자동차가 호수로 돌진한다면?
  - 하드웨어 비용이 너무 커서 접근이 어렵다
    - 이미 발표된 네트워크는 따라해 볼 수 있으나
    - 새로운 네트워크 개발에는 시간의 제약이 따른다

관련 분야

- 인공 신경망의 이해 및 설계
  - 미분, 벡터, 행렬, 확률, 통계
  - 함수에 대한 깊은 이해가 필요
- 인공 신경망을 이용한 자료 분석
  - 이미 설계된 신경망에 대입하여 결과를 이해
  - 컴퓨터 프로그래밍이 필수
    - 파이썬 – 텐서플로우 / 케라스
  - 약간의 수학적인 지식이 필요
  - 다양한 분야에서 많은 연구자들이 이용하고 있음

인공 신경망의 현재와 미래

- 결과에 대한 이유를 이해하는 것은 불가능에 가깝다
  - 복잡한 신경망을 제대로 이해하는 사람은 없다
  - 자동차가 호수로 돌진한다면?
- 특정 분야에서는 인간보다 정확하다
  - 인간도 자동차를 몰고 호수로 돌진한다
- 새로운 수학 이론이 필요?

비지도 학습
Unsupervised Learning

- 미지의 자료를 그룹으로 분류

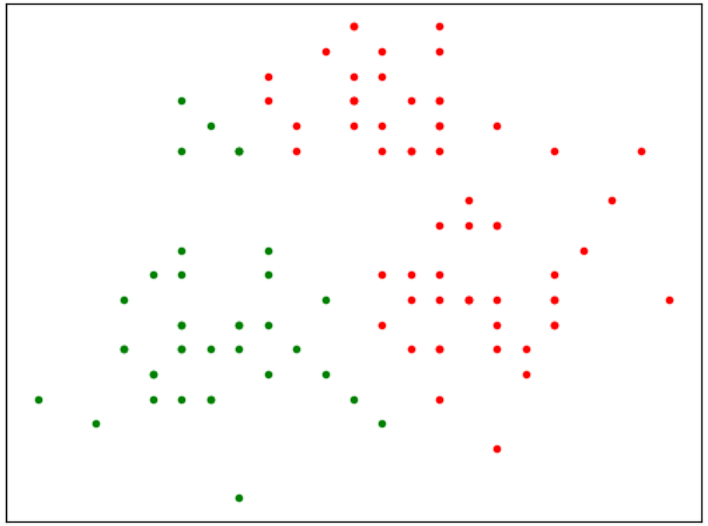
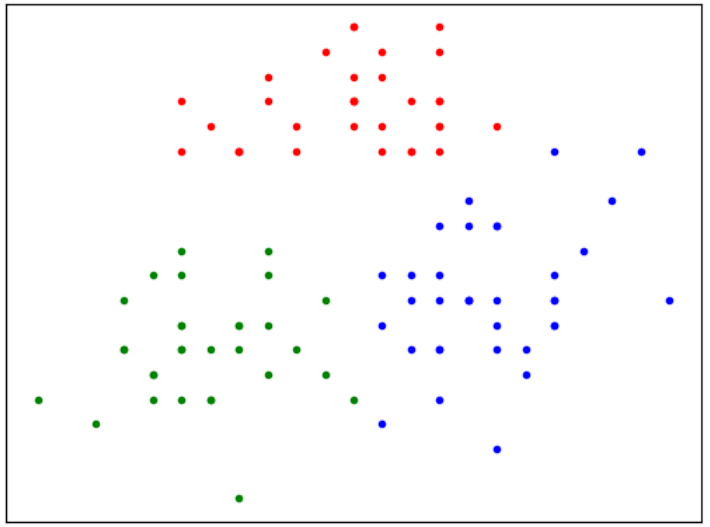
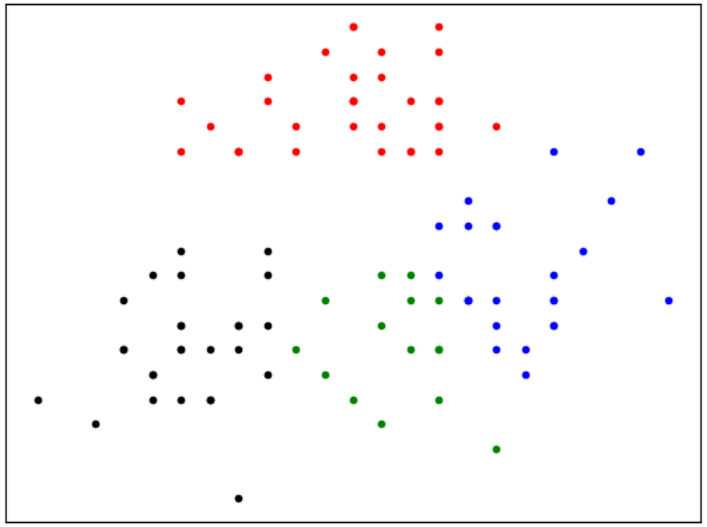

K-Means Clustering

- 알고리즘
  - K: 그룹의 개수
  - K 그룹으로 임의 분할
  - 반복
    - 각 그룹의 평균점 계산
    - 가까운 평균점으로 그룹 다시 배정

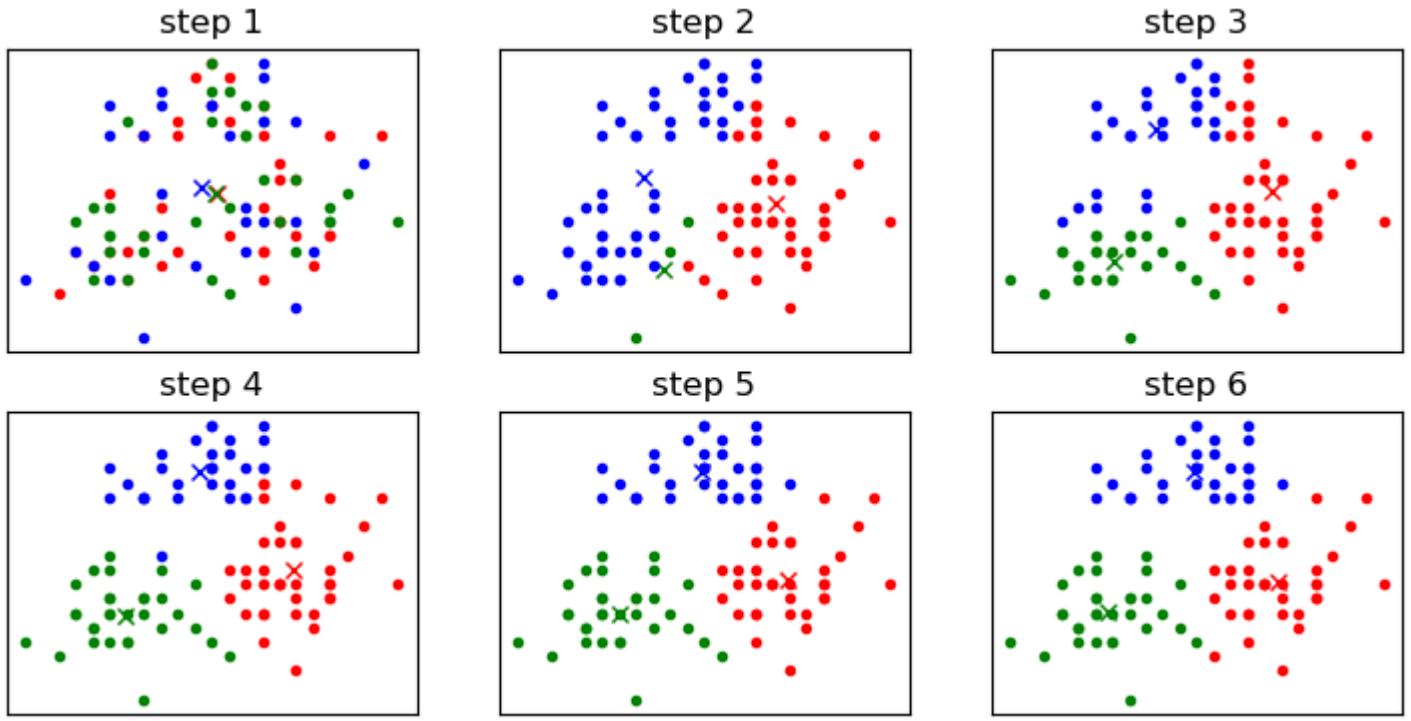

강화 학습
Reinforcement Learning

- 최적의 보상을 얻는 행동을 찾아가는 기계 학습 방법
  - Cart Pole
  - 알파고
  - 게임

격자 세계

- 이득이 가장 큰 방향은 어디인가?

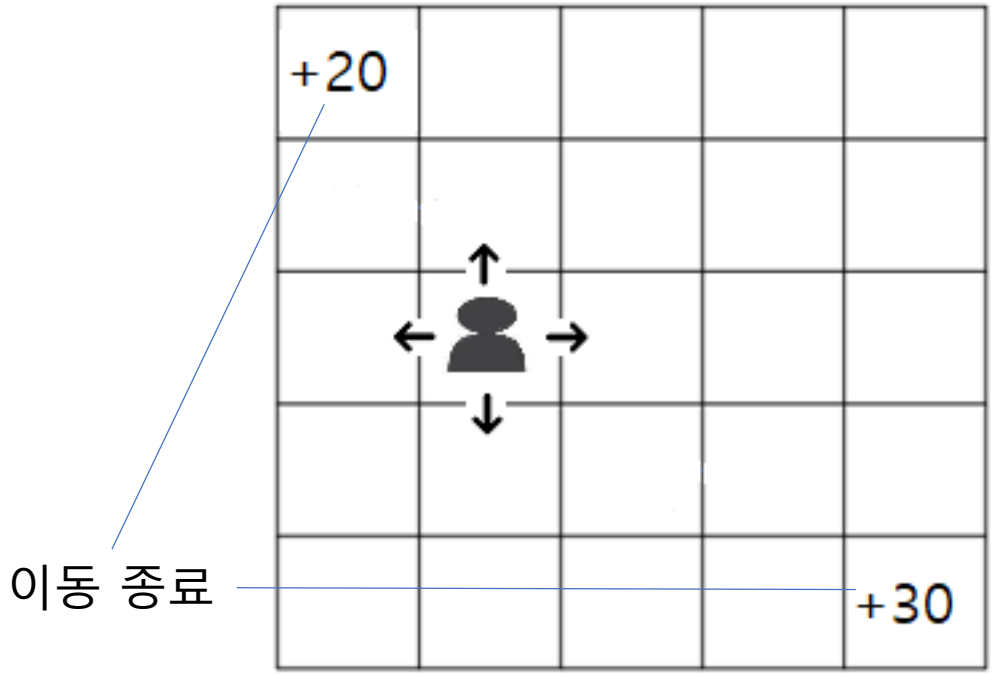

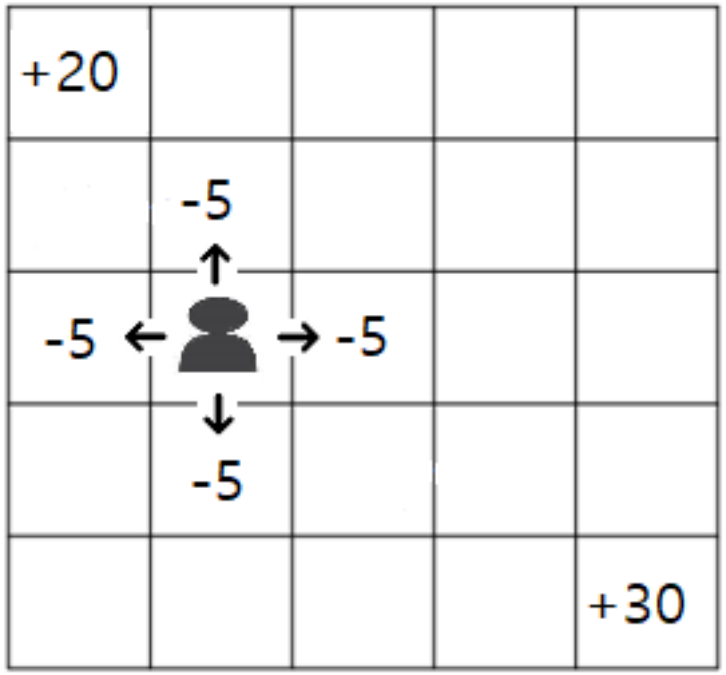

변수

- 상태(state)
- 행동(action)
- 보상(reward)
  - 행동에 대한 보상

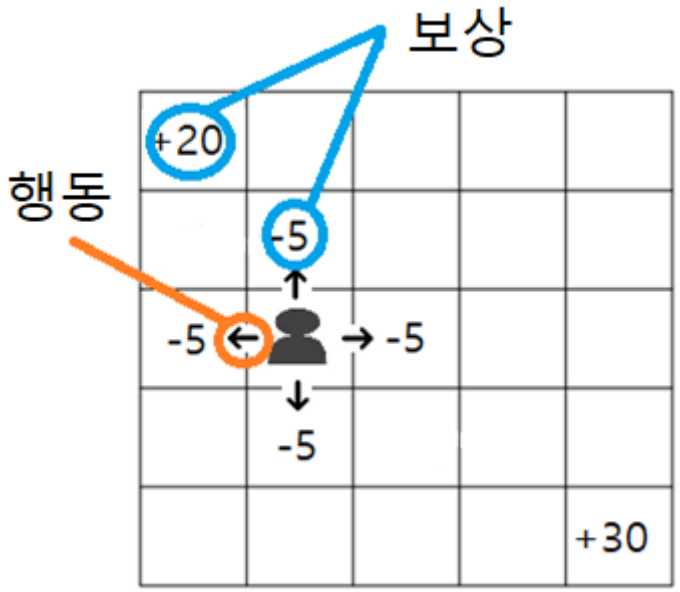

예

- 올해는 무엇을 심을까?
  - 상태 – 예상 강수량, 예상 기온, 가격, 등
  - 행동 – 작물 선택
  - 보상 – 수확
- 우산을 가지고 나갈까?
- 자동차는 어떤 방향으로 가야할까?
- 바둑 선수는 어떤 수를 둘까?

행위자와 환경
Agent and Environment

- 행위자(agent)
  - 행동 주체
  - 각 상태에서 행동 선택
- 환경(environment)
  - 행위자의 행동에 대한 보상 제공
  - 행위자의 행동에 대하여 다음 상태 결정

예

- 올해는 무엇을 심을까?
  - 행위자 – 농부
  - 환경 – ?
- 우산을 가지고 나갈까?
  - 환경 – ?
- 자동차는 어떤 방향으로 갈까?
  - 행위자 – 자동차
  - 환경 – ?
- 바둑 선수는 어떤 수를 둘까?
  - 환경 – 규칙 + 상대방

마르코프 결정 과정
MDP – Markov Decision Process

- 의사결정을 위한 수학적 모델
- 직전의 상태와 행동이 다음 상태와 보상을 결정
- $S_0 \xrightarrow{A_0} R_1, S_1 \xrightarrow{A_1} R_2, S_2 \longrightarrow$
  - S_t - 상태
  - A_t - 행동
  - R_t - 보상

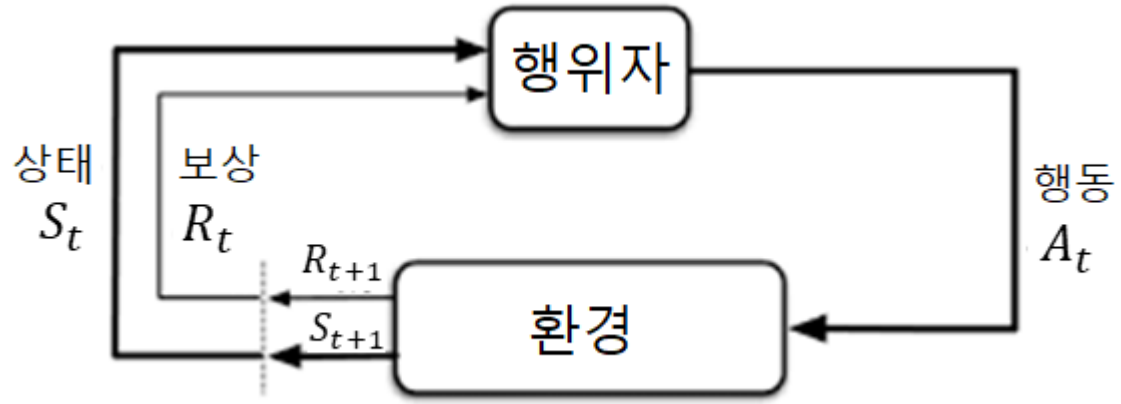

MDP

- $\mathcal{S}$ – 상태의 집합
- $\mathcal{A}$ – 행동의 집합
  - $\mathcal{A}(s)$ – 상태 s에서 취할 수 있는 행동의 집합
- $\mathcal{R}$ – 보상의 집합
  - $\mathcal{R}(s,a)$ – 상태 s에서 행동 a를 취했을 때 얻는 보상의 집합
- $p(s',r \mid s,a) = \Pr(S_t = s', R_t = r \mid S_{t-1} = s, A_{t-1} = a)$
  - 상태 s에서 행동 a를 취했을 때 상태 s'이 되고 보상 r을 얻을 확률

참고
대문자: 변수
소문자: 값

에피소드
Episode

- 행위자와 환경의 상호작용이 완료되는 과정
- $S_0 \xrightarrow{A_0} R_1, S_1 \xrightarrow{A_1} R_2, S_2 \xrightarrow{A_2} \cdots \xrightarrow{A_{T-1}} R_T, S_T$

반환
Return

- 각 타임 스텝에서 에피소드가 종료될 때까지 얻는 보상의 총합
- $G_t = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{T-t-1} R_T$
  $= \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
  $= R_{t+1} + \gamma G_{t+1}$
  - γ – 할인율(discount rate)
    - 미래에 얻을 이익을 현재 가치로 환산하기 위한 비율
    - $0 < \gamma \leq 1$

격자 세계

- 에피소드
  - $S_0 \xrightarrow{A_0} R_1, S_1 \xrightarrow{A_1} R_2, S_2 \xrightarrow{A_2} R_3, S_3 \xrightarrow{A_3} R_4, S_4$
- 할인율
  - $\gamma = 0.9$
- 반환
  - $G_0 = R_1 + \gamma R_2 + \gamma^2 R_3 + \gamma^3 R_4 + \gamma^4 R_5$
    $= -5 + 0.9 \cdot (-5) + 0.81 \cdot (-5) + 0.729 \cdot 30$
    $= 8.32$
  - $G_1 = ?$

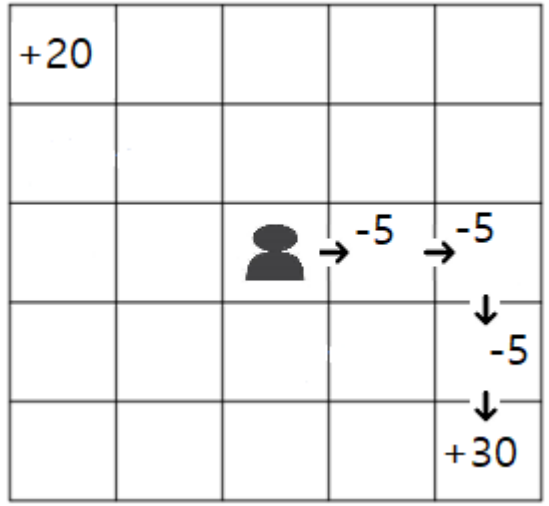

정책
Policy

- 행위자가 행동을 선택하는 방법
- 종류
  - 결정적 정책
    - 각 상태에서 취하는 행동이 결정되어 있음
  - 확률적 정책
    - 각 상태에서 확률에 따라 행동을 취함

정책의 표현

- $\pi(a|s) = \Pr(A_t = a \mid S_t = s)$
- 예
  - 결정적 정책
    - $\pi(a|s) = 0$ or 1
  - 랜덤 정책
    - $\pi(a|s)$가 균일

정리

- 행위자, 환경, 상태, 행동, 보상, 정책, 에피소드, 반환, 할인율
- 확률적으로 결정되는 것들은 무엇인가?

- 올해는 무엇을 심을까?
  - 콩을 10개 심으면 몇 개의 싹이 틀까?
- 우산을 가지고 나갈까?
  - 상태는 어제와 비슷한데 오늘도 비가 올까?
- 자동차는 어떤 방향으로 갈까?
- 바둑 선수는 어떤 수를 둘까?
  - 내가 둔 수에 대한 상대의 반응은?

상태 가치 함수

- 상태 가치
  - 정책에 의하여 행동을 선택할 경우 각 상태의 가치
- 정책 π에 대한 상태 가치 함수
  - $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$
  - 에피소드의 반환의 기댓값

격자 세계

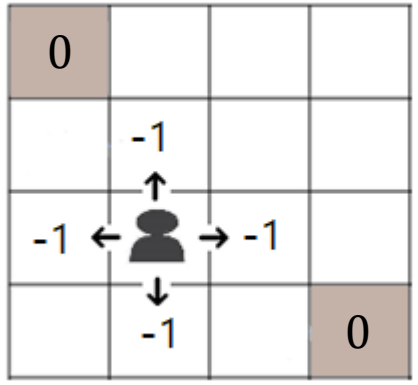

$\gamma = 1$

- 랜덤 정책을 취할 때 각 상태의 가치

0	-14	-20	-22
-14	-18	-20	-20
-20	-20	-18	-14
-22	-20	-14	0

- 최적의 정책을 취할 때 각 상태의 가치

0	-1	-2	-3
-1	-2	-3	-2
-2	-3	-2	-1
-3	-2	-1	0

행동 가치 함수

- 행동 가치
  - 정책에 의하여 행동을 선택할 경우 각 행동의 가치
- 정책 π에 대한 행동 가치 함수
  - $q_\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$

- 상태 가치와 행동 가치의 관계는?

- 랜덤 정책을 취할 때 상태 $(2,4)$에서 행동 ↓의 가치는?

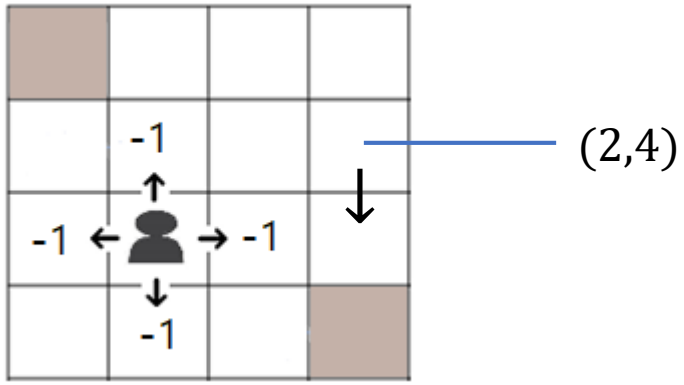

벨만 방정식
Bellman equation

- 벨만 방정식

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)[r + \gamma v_\pi(s')]$$

- 행동 가치 함수

$$q_\pi(s, a) = \sum_{s',r} p(s', r|s, a)[r + \gamma v_\pi(s')]$$

벨만 방정식의 해

- 일차 연립방정식
  - 미지수의 개수 = 상태의 개수
  - $X = AX + b$ 꼴
- 점화식
  - X_0: 임의로 초기화
  - $X_{i+1} = AX_i + b$
  - 해는 $\lim_{n\to\infty} X_n$

벨만 방정식

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)[r + \gamma v_\pi(s')]$$

해 구하기

- $v_0 \rightarrow v_1 \rightarrow v_2 \rightarrow \cdots \rightarrow v_\infty = v_\pi$

랜덤 정책 π에 대한 가치 함수

$$v_\pi(s) = \sum_{a=1}^{4} \frac{1}{4}[-1 + v_\pi(s')]$$

0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0

$k = 0$

0.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	-1.0
-1.0	-1.0	-1.0	0.0

$k = 1$

0.0	-1.7	-2.0	-2.0
-1.7	-2.0	-2.0	-2.0
-2.0	-2.0	-2.0	-1.7
-2.0	-2.0	-1.7	0.0

$k = 2$

0.0	-2.4	-2.9	-3.0
-2.4	-2.9	-3.0	-2.9
-2.9	-3.0	-2.9	-2.4
-3.0	-2.9	-2.4	0.0

$k = 3$

0.0	-6.1	-8.4	-9.0
-6.1	-7.7	-8.4	-8.4
-8.4	-8.4	-7.7	-6.1
-9.0	-8.4	-6.1	0.0

$k = 10$

0.0	-14.	-20.	-22.
-14.	-18.	-20.	-20.
-20.	-20.	-18.	-14.
-22.	-20.	-14.	0.0

$k = \infty$

최적 가치 함수와 최적 정책

- 최적 가치 함수
  - 상태의 최대 가치
  - $v_*(s) = \max_\pi v_\pi(s)$

- 최적 정책
  - 가장 우수한 정책 π_*
  - $v_{\pi_*}(s) = v_*(s)$

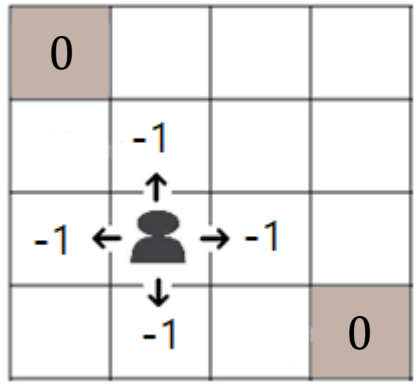

$\gamma = 1$

최적 가치

0	−1	−2	−3
−1	−2	−3	−2
−2	−3	−2	−1
−3	−2	−1	0

최적 정책 구하기

- π_0: 임의의 정책
- $\pi_0 \rightarrow v_{\pi_0} \rightarrow \pi_1 \rightarrow v_{\pi_1} \rightarrow \cdots \rightarrow \pi_*$
- $v_{\pi_*} = v_*$

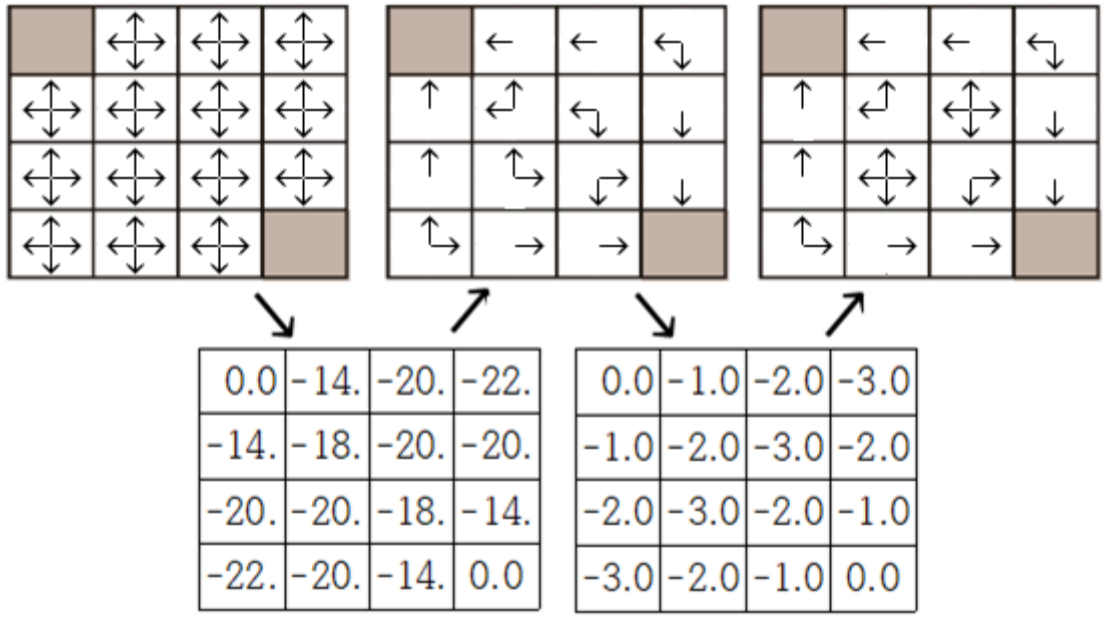

Dynamic Programming

- 최적화 문제를 해결하는 것
  - 가장 우수한 정책 찾기
- 장점
  - 거의 정확한 값을 계산할 수 있다
- 단점
  - 모든 경우의 수를 생각해야 한다
    - 바둑에서 상태의 개수 ≈ 361!
    - 시간의 한계
    - 메모리의 한계

몬테 카를로 방법
Monte Carlo Methods

- q_π의 근삿값
  - 에피소드의 표본에 대하여 계산

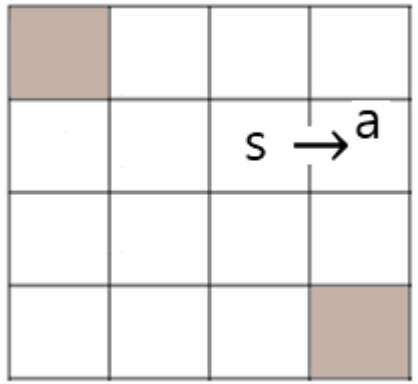

$q_\pi(s,a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$
모든 에피소드에 대한 반환의 평균을 계산

시간차 학습
Temporal Difference Learning

- 에피소드의 각 단계에서 상태 가치 함수를 다시 설정
- 상태의 가치를 다음 상태의 가치로 보정
  - $v(S_t) \leftarrow v(S_t) + \alpha[R_{t+1} + \gamma v(S_{t+1}) - v(S_t)]$
  - α – 학습률

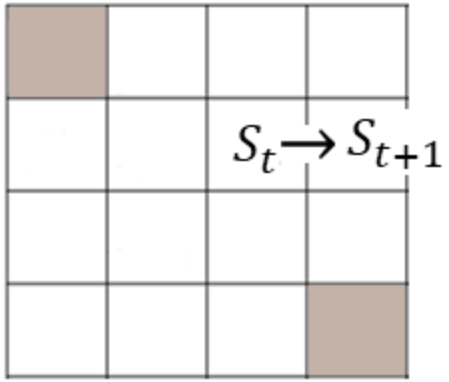

예: 시간차 학습

$$\pi(a|s) = 0.25,\ \alpha = 0.01,\ \gamma = 1$$

0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0

에피소드 0

0.0	0.0	0.0	0.0
-.03	-.02	-.02	-.02
-.01	-.04	-.02	0.0
-.03	-.07	-.01	0.0

에피소드 1

0.0	0.0	0.0	0.0
-.05	-.02	-.02	-.02
-.01	-.04	-.02	0.0
-.03	-.08	-.01	0.0

에피소드 2

0.0	-13.	-19.	-21.
-14.	-17.	-19.	-19.
-19.	-19.	-17.	-13.
-21.	-19.	-15.	0.0

에피소드 100000

Sarsa

- 에피소드를 따라 행동 가치 함수를 다시 설정
  - $q(S_t, A_t) \leftarrow q(S_t, A_t) + \alpha[R_{t+1} + \gamma q(S_{t+1}, A_{t+1}) - q(S_t, A_t)]$
- $S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1}$를 사용하기 때문에 "sarsa"라 부른다

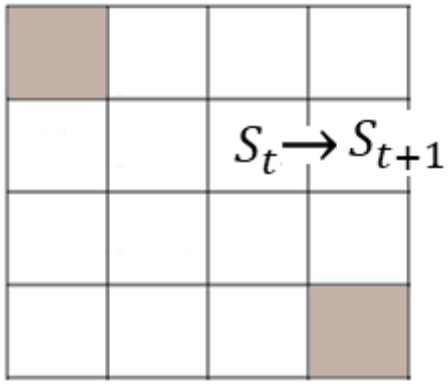

Q-learning

- $q(S_t, A_t) \longleftarrow q(S_t, A_t) + \alpha[R_{t+1} + \gamma \max_a q(S_{t+1}, a\ ) - q(S_t, A_t)]$
  - $\max_a q(S_{t+1}, a\ )$는 정책에 무관
  - 에피소드를 따라 계산

알파고

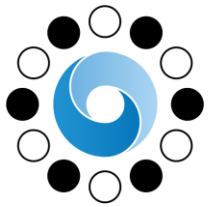

AlphaGo

- 가치가 큰 수(행동)를 선택
- 모든 수를 시도해 볼 수는 없다
- 이길 확률이 높은 그림과 유사한 그림을 만드는 수들을 시도해 본다
  - 합성곱 신경망

강화 학습의 현재

- 상태의 가치를 알 수 없다
  - 상태가 너무 많다
- 어떤 행동을 시도해 볼 것인가?
  - 확률에 의하여 결정된다
  - 불확실성이 존재한다

프로그래밍

- 파이썬
  - 배우기 쉬운 언어